

TUGAS 3

Logistic Regression, K-Nearest Neighbor, Naïve Bayes, Decision Tree

Disusun untuk memenuhi tugas mata kuliah
Pembelajaran Mesin A



KELOMPOK 1 :

Muhammad Raihan	(2208107010021)
Ammar Qurthuby	(2208107010031)
Azri Harniza	(2208107010034)
M.Syahidal Akbar Zas	(2208107010045)

PROGRAM STUDI INFORMATIKA

UNIVERSITAS SYIAH KUALA

2025

1. Pemahaman Dataset

1.1 Sumber Data dan Variabel yang Digunakan

Dataset yang digunakan dalam proyek ini adalah **Dataset Kanker Payudara Wisconsin (Diagnostic)** yang tersedia di repository scikit-learn. Dataset ini berisi fitur-fitur yang diekstrak dari gambar digital dari aspirasi jarum halus (FNA) dari massa payudara yang menggambarkan karakteristik inti sel yang terlihat dalam gambar.

Variabel dalam Dataset:

```
print(df.columns)
```

```
Index(['id', 'diagnosis', 'radius_mean', 'texture_mean', 'perimeter_mean',  
      'area_mean', 'smoothness_mean', 'compactness_mean', 'concavity_mean',  
      'concave points_mean', 'symmetry_mean', 'fractal_dimension_mean',  
      'radius_se', 'texture_se', 'perimeter_se', 'area_se', 'smoothness_se',  
      'compactness_se', 'concavity_se', 'concave points_se', 'symmetry_se',  
      'fractal_dimension_se', 'radius_worst', 'texture_worst',  
      'perimeter_worst', 'area_worst', 'smoothness_worst',  
      'compactness_worst', 'concavity_worst', 'concave points_worst',  
      'symmetry_worst', 'fractal_dimension_worst'],  
      dtype='object')
```

- **Target Variable:** Diagnosis (0 = malignant/ganas, 1 = benign/jinak)
- **Fitur Variabel:** Terdapat 30 fitur numerik yang merupakan pengukuran dari 10 karakteristik inti sel:
 - radius
 - texture
 - perimeter
 - area
 - smoothness
 - compactness
 - concavity
 - concave points
 - symmetry
 - fractal dimension

Setiap karakteristik memiliki 3 nilai: mean, standard error, dan "worst" (mean dari 3 nilai terburuk).

1.2 Statistik Deskriptif dan Visualisasi Awal Data

Untuk memahami dataset, dilakukan analisis statistik deskriptif dan visualisasi data awal. Berikut adalah langkah-langkah yang dilakukan:

1. Melihat informasi dataset

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 32 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   id                                     569 non-null    int64
1   diagnosis                             569 non-null    object
2   radius_mean                           569 non-null    float64
3   texture_mean                           569 non-null    float64
4   perimeter_mean                         569 non-null    float64
5   area_mean                             569 non-null    float64
6   smoothness_mean                       569 non-null    float64
7   compactness_mean                      569 non-null    float64
8   concavity_mean                        569 non-null    float64
9   concave points_mean                   569 non-null    float64
10  symmetry_mean                         569 non-null    float64
11  fractal_dimension_mean                 569 non-null    float64
12  radius_se                              569 non-null    float64
13  texture_se                             569 non-null    float64
14  perimeter_se                           569 non-null    float64
15  area_se                                569 non-null    float64
16  smoothness_se                          569 non-null    float64
17  compactness_se                         569 non-null    float64
18  concavity_se                           569 non-null    float64
19  concave points_se                      569 non-null    float64
...
30  symmetry_worst                         569 non-null    float64
31  fractal_dimension_worst                 569 non-null    float64
dtypes: float64(30), int64(1), object(1)
memory usage: 142.4+ KB
```

2. Statistik deskriptif


```
df.describe()
```

	id	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean
count	5.690000e+02	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000
mean	3.037183e+07	14.127292	19.289649	91.969033	654.889104	0.096360	0.104341	0.088799
std	1.250206e+08	3.524049	4.301036	24.298981	351.914129	0.014064	0.052813	0.079720
min	8.670000e+03	6.981000	9.710000	43.790000	143.500000	0.052630	0.019380	0.000000
25%	8.692180e+05	11.700000	16.170000	75.170000	420.300000	0.086370	0.064920	0.029560
50%	9.060240e+05	13.370000	18.840000	86.240000	551.100000	0.095870	0.092630	0.061540
75%	8.813129e+06	15.780000	21.800000	104.100000	782.700000	0.105300	0.130400	0.130700
max	9.113205e+08	28.110000	39.280000	188.500000	2501.000000	0.163400	0.345400	0.426800

8 rows × 31 columns

3. Melihat distribusi target

```
plt.hist(df['diagnosis'])  
plt.title('Diagnosis(M=1, B=0)')  
plt.show()
```



Dari statistik deskriptif, kita dapat melihat bahwa dataset terdiri dari 569 sampel dengan 30 fitur numerik dan 1 target. Fitur-fitur tersebut memiliki skala yang berbeda-beda, dengan beberapa fitur memiliki rentang nilai yang jauh lebih besar dari yang lain.

Visualisasi distribusi target menunjukkan lebih banyak sampel yang jinak (benign) dibandingkan dengan sampel yang ganas (malignant). Distribusi target adalah:

- Benign (1): 357 sampel (62.7%)
- Malignant (0): 212 sampel (37.3%)

2. Eksplorasi Data dan Pra-pemrosesan

2.1 Menangani Missing Values

```
df.isnull().sum()


id          0
diagnosis   0
radius_mean 0
texture_mean 0
perimeter_mean 0
area_mean   0
smoothness_mean 0
compactness_mean 0
concavity_mean 0
concave points_mean 0
symmetry_mean 0
fractal_dimension_mean 0
radius_se    0
texture_se    0
perimeter_se  0
area_se       0
smoothness_se 0
compactness_se 0
concavity_se  0
concave points_se 0
symmetry_se   0
fractal_dimension_se 0
radius_worst  0
texture_worst 0
perimeter_worst 0
...
concavity_worst 0
concave points_worst 0
symmetry_worst  0
fractal_dimension_worst 0
dtype: int64
```

Dataset ini diperiksa untuk missing values dan ternyata tidak memiliki nilai yang hilang, sehingga tidak diperlukan penanganan khusus.


2.2 EDA

```
plt.figure(figsize=(20,15))
plotnumber=1
for column in df:
    if plotnumber<=30:
        ax = plt.subplot(5,6, plotnumber)
        sns.distplot(df[column])
        plt.xlabel(column)
        plotnumber+=1

plt.tight_layout()
plt.show()
```



2.2 Analisis Korelasi antara Variabel



Analisis korelasi menunjukkan bahwa beberapa fitur memiliki korelasi yang kuat dengan target, seperti:

- concave_points_mean: korelasi tinggi positif dengan tumor ganas
- concavity_mean: korelasi tinggi positif dengan tumor ganas
- perimeter_mean dan area_mean: korelasi tinggi positif dengan tumor ganas
- symmetry_mean dan texture_mean: korelasi lebih rendah dengan target

Ada juga beberapa fitur yang berkorelasi tinggi antar sesamanya, menunjukkan kemungkinan adanya multikolinearitas dalam dataset.

2.3 Feature Selection

```
# feature selection
corr_matrix = df.corr().abs()
mask = np.triu(np.ones_like(corr_matrix, dtype=bool))
tri_df = corr_matrix.mask(mask)

to_drop = [x for x in tri_df.columns if any(tri_df[x]>0.92)]

df = df.drop(to_drop, axis=1)

print(df.shape[1])
```

23

Langkah ini melakukan seleksi fitur dengan menghapus kolom-kolom yang saling berkorelasi tinggi (lebih dari 0.92), agar model tidak terganggu oleh informasi yang berlebihan atau redundan. Hasil akhirnya adalah jumlah fitur yang lebih sedikit namun tetap informatif.

2.4 Normalisasi atau Standarisasi Data

1. Pisahkan fitur dan target

```
x=df.drop('diagnosis', axis=1)
y=df['diagnosis']
```

2. Pembagian data training dan testing

```
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=0)
```

3. Standarisasi data

```
# scaling data
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

Data dinormalisasi menggunakan StandardScaler dari sklearn untuk memastikan semua fitur memiliki skala yang sama, yang penting untuk algoritma seperti KNN dan Logistic Regression. Standarisasi dilakukan terpisah untuk data training dan testing untuk menghindari data leakage.

3. Implementasi Model

Dalam proyek ini, empat model machine learning diimplementasikan:

3.1 Logistic Regression

```
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
print(accuracy_score(y_train, log_reg.predict(X_train)))
log_reg_acc = accuracy_score(y_test, log_reg.predict(X_test))
print(log_reg_acc)
y_pred = log_reg.predict(X_test)
print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))
```

Logistic Regression adalah algoritma klasifikasi linear yang digunakan untuk memprediksi probabilitas kejadian dari variabel dependen kategoris. Dalam konteks ini, model digunakan untuk memprediksi apakah tumor bersifat jinak atau ganas.

3.2 K-Nearest Neighbors (KNN)

```
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
print(accuracy_score(y_train, knn.predict(X_train)))
knn_acc = accuracy_score(y_test, knn.predict(X_test))
print(knn_acc)
y_pred = knn.predict(X_test)
print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))
```

KNN adalah algoritma yang mengklasifikasikan data berdasarkan similarity dengan data lain. Algoritma ini menggunakan jarak (biasanya Euclidean) untuk menentukan "tetangga"

terdekat. Parameter `n_neighbors=5` menunjukkan bahwa model akan mencari 5 tetangga terdekat untuk melakukan klasifikasi.

3.3 Naïve Bayes

```
from yellowbrick.classifier import ConfusionMatrix
cm = ConfusionMatrix(naive_bayes)
cm.fit(X_train, y_train)
cm.score(X_test, y_test)
```

Naïve Bayes adalah algoritma klasifikasi probabilistik yang didasarkan pada teorema Bayes dengan asumsi independensi antara fitur-fitur. GaussianNB digunakan karena fitur-fitur dalam dataset bersifat kontinu dan diasumsikan mengikuti distribusi Gaussian.

3.4 Decision Tree

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import GridSearchCV

dtc = DecisionTreeClassifier()

parameters = {
    'criterion':['gini','entropy'],
    'max_depth':range(2,32,1),
    'min_samples_leaf':range(1,10,1),
    'min_samples_split':range(2,10,1),
    'splitter':['best','random']
}

grid_search_dt = GridSearchCV(dtc, parameters, cv=5, n_jobs=-1, verbose=1)
grid_search_dt.fit(X_train, y_train)
```

Decision Tree adalah model prediktif yang menggunakan serangkaian keputusan berbasis aturan untuk mendapatkan prediksi akhir. Parameter `random_state=42` digunakan untuk memastikan reproduktibilitas hasil.

4. Evaluasi Model

4.1 Evaluasi model Logistic Regression

```
0.989010989010989
0.9649122807017544
[[66  1]
 [ 3 44]]
```

	precision	recall	f1-score	support
0	0.96	0.99	0.97	67
1	0.98	0.94	0.96	47
accuracy			0.96	114
macro avg	0.97	0.96	0.96	114
weighted avg	0.97	0.96	0.96	114


4.1 Evaluasi model KNN

```
0.967032967032967
0.956140350877193
[[66  1]
 [ 4 43]]
```

	precision	recall	f1-score	support
0	0.94	0.99	0.96	67
1	0.98	0.91	0.95	47
accuracy			0.96	114
macro avg	0.96	0.95	0.95	114
weighted avg	0.96	0.96	0.96	114

4.3 Evaluasi model Naive Bayes

	precision	recall	f1-score	support
0	0.91	0.91	0.91	67
1	0.87	0.87	0.87	47
accuracy			0.89	114
macro avg	0.89	0.89	0.89	114
weighted avg	0.89	0.89	0.89	114




4.4 Evaluasi model Decision Tree

```
0.9736263736263736
0.9385964912280702
[[62  5]
 [ 2 45]]
```

	precision	recall	f1-score	support
0	0.97	0.93	0.95	67
1	0.90	0.96	0.93	47
accuracy			0.94	114
macro avg	0.93	0.94	0.94	114
weighted avg	0.94	0.94	0.94	114

5. Perbandingan model

5.1 Grafik ROC




Kurva ROC (Receiver Operating Characteristic) menunjukkan trade-off antara True Positive Rate (sensitivitas) dan False Positive Rate (1-spesifisitas) pada berbagai threshold. Area di bawah kurva ROC (AUC-ROC) adalah ukuran kinerja model - semakin tinggi nilainya, semakin baik modelnya. Kinerja keempat model dibandingkan menggunakan metrik AUC-ROC. Hasil menunjukkan bahwa semua model memiliki performa yang baik, dengan AUC di atas 0.89.

- **Logistic Regression:** Menunjukkan performa terbaik dengan AUC-ROC sekitar **0.96**, mencerminkan kemampuan klasifikasi yang sangat tinggi.
- **Decision Tree:** Memiliki AUC-ROC sekitar **0.95**, menunjukkan performa yang bagus dan hampir setara dengan Logistic Regression.
- **K-Nearest Neighbors (KNN):** Juga mencatat AUC-ROC sekitar **0.95**, menunjukkan model ini juga setara dengan Decision Tree.
- **Naive Bayes:** Sedikit lebih rendah dibanding model lain dengan AUC-ROC sekitar **0.89**, namun masih menunjukkan performa yang baik.

Dari keempat model, **Logistic Regression** memberikan performa terbaik berdasarkan nilai AUC-ROC, menunjukkan keunggulannya dalam prediksi kanker payudara.

5.2 Performance Evaluation



Kinerja empat model klasifikasi dibandingkan berdasarkan dua metrik utama: **Akurasi (%)** dan **ROC (%)**.

- **Logistic Regression (LR):**
Memiliki akurasi sekitar **96%** dan nilai ROC sekitar **99%**, menunjukkan performa yang sangat baik dan konsisten.
- **Decision Tree (DT):**
ROC tertinggi, mendekati **100%**, namun akurasinya sedikit lebih rendah dibanding LR, sekitar **94-95%**. Ini menunjukkan model mampu mengenali pola, tetapi ada potensi overfitting.
- **K-Nearest Neighbors (KNN):**
Akurasi dan ROC stabil di kisaran **95-97%**, menunjukkan kinerja yang andal.
- **Naive Bayes:**
Mempunyai akurasi paling rendah (sekitar **90%**), meskipun ROC-nya tetap cukup baik (**~96%**), menandakan model dapat membedakan kelas meski presisinya tidak setinggi model lain.

Logistic Regression adalah model terbaik berdasarkan keseimbangan antara akurasi dan ROC. Sementara **Decision Tree** unggul di ROC, tapi tidak di akurasi. **Naive Bayes** tertinggal dibanding model lainnya.

6. Kesimpulan

Berdasarkan analisis hasil evaluasi model klasifikasi dan visualisasi performa dari gambar kurva ROC dan grafik perbandingan, dapat ditarik kesimpulan menyeluruh tentang keempat model yang digunakan untuk prediksi kanker payudara.

6.1 Ringkasan Performa Model

1. **Logistic Regression (LR):**
 - Akurasi: 96.4%
 - ROC-AUC: 0.96
 - Presisi dan recall seimbang untuk kedua kelas
 - Matriks konfusi: [66, 1; 3, 44]
2. **Decision Tree (DT):**
 - Akurasi: 93.8%
 - ROC-AUC: 0.95
 - Performa yang baik dalam recall untuk kelas 1 (0.96)
 - Matriks konfusi: [62, 5; 2, 45]
3. **K-Nearest Neighbors (KNN):**
 - Akurasi: 95.6%
 - ROC-AUC: 0.95
 - Performa mirip dengan LR, tetapi recall sedikit lebih rendah untuk kelas 1
 - Matriks konfusi: [66, 1; 4, 43]
4. **Naive Bayes (NB):**
 - Akurasi: 89.0%
 - ROC-AUC: 0.89
 - Performa terendah di semua metrik evaluasi
 - Presisi dan recall sekitar 0.87-0.91 untuk kedua kelas

6.2 Analisis dari Visualisasi

Kurva ROC dan grafik perbandingan performa memberikan wawasan tambahan yang memperkuat kesimpulan sebelumnya:

1. **Kurva ROC** menunjukkan:
 - Logistic Regression memiliki area di bawah kurva tertinggi (0.96), mengindikasikan kemampuan diskriminasi terbaik
 - Decision Tree dan KNN memiliki nilai ROC-AUC yang sama (0.95) dan kurva yang hampir berhimpit
 - Naive Bayes memiliki kurva ROC yang lebih rendah dan area di bawah kurva terkecil (0.89)
 - Semua model jauh di atas garis diagonal (klasifikasi acak), menunjukkan performa prediktif yang baik
2. **Grafik Perbandingan** menampilkan:

- Logistic Regression memiliki keseimbangan terbaik antara akurasi (96.4%) dan ROC (99%)
- Decision Tree memiliki ROC tertinggi (100%) tetapi akurasi yang lebih rendah (94.8%)
- KNN memiliki performa yang stabil dan seimbang
- Naive Bayes konsisten menunjukkan performa terendah di kedua metrik

6.3 Kesimpulan Akhir

1. **Logistic Regression** adalah model terbaik secara keseluruhan untuk kasus prediksi kanker payudara ini, dengan keseimbangan optimal antara akurasi tinggi, area ROC besar, dan performa yang baik untuk kedua kelas. Model ini memberikan tingkat false negative yang rendah (penting dalam konteks medis) dengan tetap mempertahankan presisi yang tinggi.
2. **KNN** dan **Decision Tree** merupakan alternatif yang sangat baik dengan performa yang hampir setara dengan Logistic Regression. Decision Tree memiliki keunggulan sedikit dalam recall untuk kelas positif, yang bisa menjadi pertimbangan penting dalam kasus medis dimana mendeteksi semua kasus positif lebih diutamakan.
3. **Naive Bayes**, meskipun masih memberikan hasil yang cukup baik dengan akurasi 89%, secara konsisten menunjukkan performa yang lebih rendah dibandingkan ketiga model lainnya di semua metrik dan visualisasi.
4. Dalam konteks prediksi kanker payudara, dimana mendeteksi kasus positif secara akurat sangat penting (menghindari false negative), baik Logistic Regression maupun Decision Tree menawarkan keunggulan tertentu. Logistic Regression memberikan keseimbangan terbaik secara keseluruhan, sementara Decision Tree menunjukkan recall tertinggi untuk kelas positif.
5. Keempat model menunjukkan performa yang jauh di atas klasifikasi acak, mengindikasikan bahwa fitur-fitur yang digunakan memiliki daya prediktif yang tinggi untuk kasus kanker payudara.

Dengan mempertimbangkan semua aspek evaluasi dan visualisasi, Logistic Regression adalah pilihan utama untuk implementasi model prediksi kanker payudara dalam kasus ini, dengan Decision Tree sebagai alternatif yang valid jika sensitivitas tinggi terhadap kasus positif menjadi prioritas utama.